STAT6207 · HW4 · 实验报告

关键词驱动的 CV–JD 匹配

本地 LLM 关键词抽取 · 关键词聚类 · 自编码器检索

10 组标准配对　110 份 CV　前 10 检索

数据：Anonymised-CVs-100 + JD + Hired CV examples

模型：Qwen2.5-Coder-14B-Instruct（LM Studio，本地）

日期：2026-11-07

摘要

本项目研究在职位描述（JD）与简历（CV）均为非结构化自然语言的条件下，如何用“本地 LLM 关键词抽取 → 关键词合并/聚类 → 自编码器编码 → 向量检索”的流水线完成 CV–JD 匹配。数据包含 10 份带“实际被雇佣 CV”的标准 JD–CV 对，以及 100 份匿名 CV；候选池共 110 份 CV。关键词由本地 Qwen2.5-Coder-14B-Instruct 抽取，后续聚类、编码和检索均由非 LLM 程序完成。主评估采用 leave-one-pair-out（LOPO）：每折用 9 组 GT + 100 份无标签 CV 训练，留出 1 组评估，10 折平均。主指标为 Recall@10，并报告 Recall@5、MRR@10、平均排名与 Wilson 95% 置信区间。

> **主要结果**：LOPO Recall@10 = **0.800**；TF-IDF 基线 = **0.800**；Δ = **+0.000**；全量训练上界（in-sample）= **1.000**。

1. 任务与数据

1.1 任务定义

给定一份 JD 和一组 CV，系统需要返回与 JD 最匹配的前 10 份 CV。匹配信号只来自自然语言文本中抽取出的关键词，不使用人工匹配标签作为输入特征；10 组 GT 只用于监督训练和评估。

1.2 数据

- **10 份标准 JD**：来自 `JD + Hired CV examples` 每份 PDF 的前半部分；自然语言职位描述。
- **10 份 hired CV**：同一 PDF 的 `CV OF THE HIRED CANDIDATE` 部分；作为每份 JD 的唯一已知正例。
- **100 份匿名 CV**：`Anonymised-CVs-100`；作为无标签候选与无监督训练语料。
- **候选池**：100 + 10 = **110 份 CV**。10 份 hired CV 不在 100 份匿名 CV 中。
- **Excel 未使用**：本任务不依赖 Manatal 表的结构化标签。

2. 方法

2.1 本地 LLM 关键词抽取

使用 LM Studio 本地部署的 **Qwen2.5-Coder-14B-Instruct**，temperature=0，要求模型输出固定 JSON schema。JD 与 CV 使用同一 schema：`role_title`、`seniority`、`years_experience`、`location`、`languages`、`keywords[]`；每个关键词包含 `term`、`category`、`importance`（1–3）。抽取结果写入 JSONL 并缓存，支持断点续跑。120 份文档平均 24.5 个关键词（范围 12–46）；3 份超长输出用更大 token 预算重试后全部合法。

2.2 关键词合并与聚类

先做别名归一化（如 JS→JavaScript、Golang→Go、Postgres→PostgreSQL），再用本地 Nomic embedding 模型（非生成式 LLM）对关键词向量化，并用 cosine + 层次聚类合并相似词；`java`、`javascript`、`sql` 等易混词设为保护词，避免误合并。每个 cluster 选择文档频率最高的词作为 canonical term，最终构建 120 份文档 × 词表的 TF-IDF 矩阵。

2.3 自编码器

AE 结构为 `V → 512 → 256 → 32 → 256 → 512 → V`，使用 GELU、Dropout、AdamW 和 denoising reconstruction。除重构损失外，在 bottleneck 上加入 supervised contrastive / listwise retrieval loss：每个 JD 的 positive 是它的 hired CV，其余 109 份 CV 为 negatives。这样 AE 既学习文档表示，也直接从 10 组 GT 学习“匹配”。bottleneck 做了 16/32/64 的消融，32 维最好。

2.4 检索与评估

JD 与 CV 均编码为 32 维单位向量，按 cosine similarity 排序，返回 Top-10。主评估为 leave-one-pair-out：每折留出 1 组 GT，用其余 9 组 + 100 份匿名 CV 训练，再在 110 份 CV 中检索；10 折平均。另报全部 10 组训练的 in-sample 上界，以及 TF-IDF、关键词重叠、BM25 三个无监督基线。

3. 实验结果

> **Recall@10 定义**：每个 JD，如果 hired CV 出现在 Top-10 记 1，否则记 0；对 10 个 query 取平均。每个 query 只有 1 份相关 CV，因此 Recall@10 等于 HitRate@10。

方法	Recall@10	Recall@5	MRR@10	平均排名	95% CI（R@10）
TF-IDF 余弦	0.800	0.600	0.440	10.6	[0.490, 0.943]
关键词重叠	0.700	0.500	0.472	12.0	[0.397, 0.892]
BM25	0.800	0.700	0.471	10.0	[0.490, 0.943]
AE + 监督（in-sample）	1.000	1.000	1.000	1.0	[0.722, 1.000]
AE + 监督（LOPO）	0.800	0.400	0.320	9.3	[0.490, 0.943]

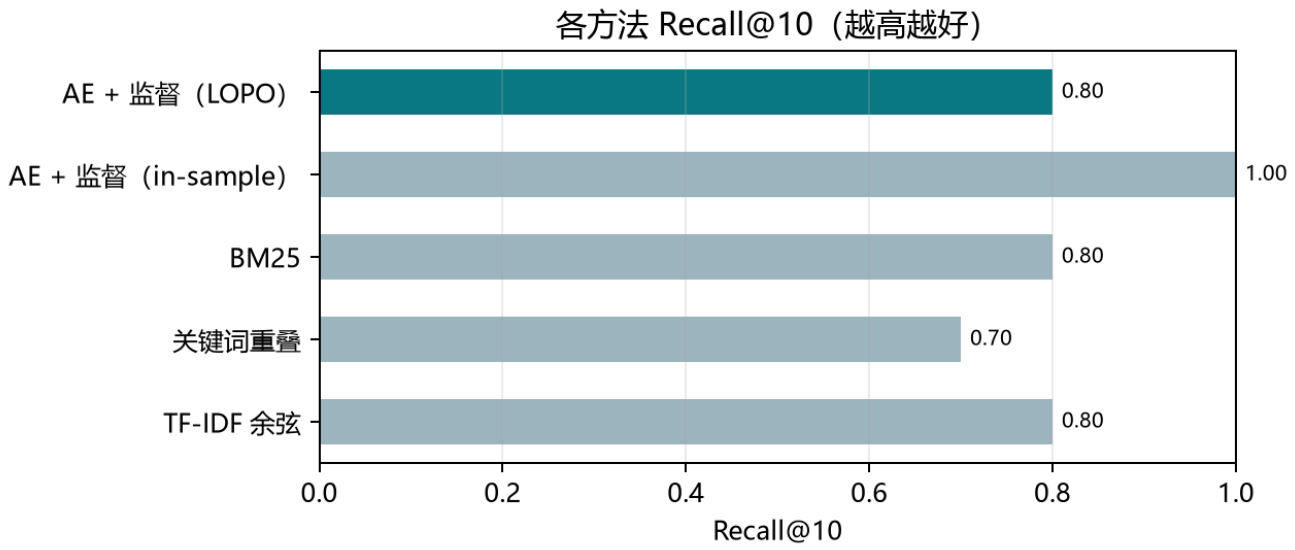


图 1. 各方法 Recall@10。

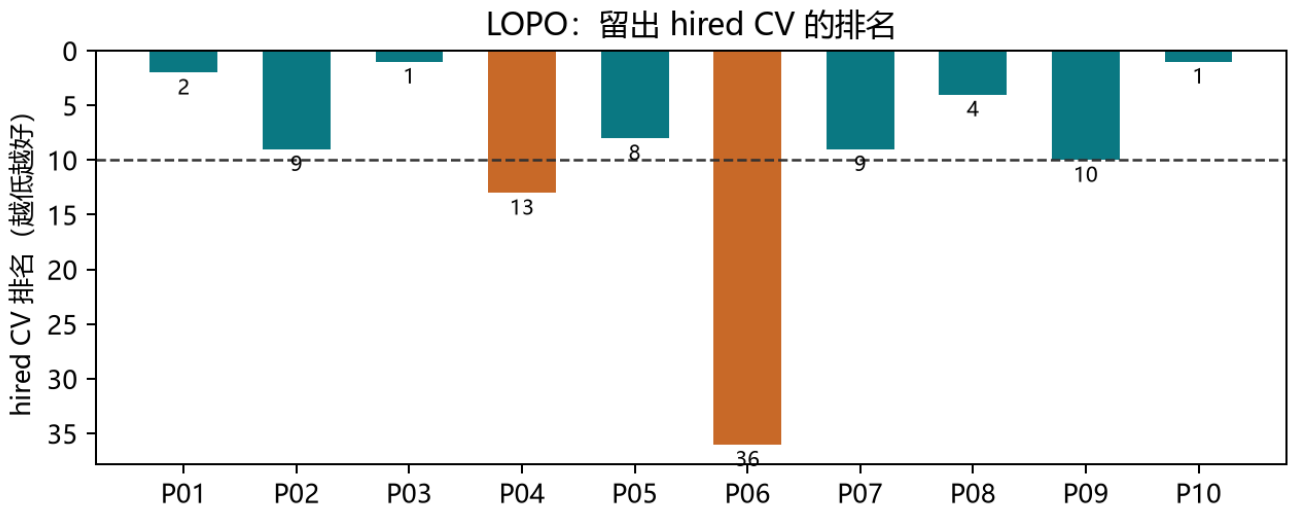


图 2. LOPO 中 hired CV 的排名（越低越好）。

JD / 职位	Hired CV	排名	命中@10	Top-1 返回
P01 Regional Finance Controller	HIRED_P01	2	✓	CV-082
P02 Sales Manager in Indonesia	HIRED_P02	9	✓	CV-062
P03 GTM Marketing Manager / Lead	HIRED_P03	1	✓	HIRED_P03
P04 Data Engineer	HIRED_P04	13	✗	CV-043
P05 Product Manager — WMS & Warehouse Integrations	HIRED_P05	8	✓	CV-065
P06 Deployment Strategist	HIRED_P06	36	✗	CV-024
P07 Marketing Manager (HK & SG)	HIRED_P07	9	✓	CV-092
P08 Field Service Engineer (FSE)	HIRED_P08	4	✓	CV-050
P09 Tech Lead	HIRED_P09	10	✓	CV-010
P10 Regional Lead Designer UI/UX	HIRED_P10	1	✓	HIRED_P10

完整的每个 JD × Top-10 明细见附录 C。

4. 错误分析

下表列出 LOPO 中未命中（rank > 10）的案例。最后一列是 JD 中出现、但 positive CV 未覆盖的关键词，用于区分“关键词抽取/聚类问题”和“候选人确实缺少 must-have 技能”。

JD / 职位	排名	Top-1	JD∩positive	positive 缺失关键词
P04 Data Engineer	13	CV-043	azure databricks, etl/elt, java, power bi, python, scala	azure synapse, azure, azure data engineer associate, data quality, r, pyspark
P06 Deployment Strategist	36	CV-024		blocker removal, agent refinement, production launches, ai solutions, risk management, ai product

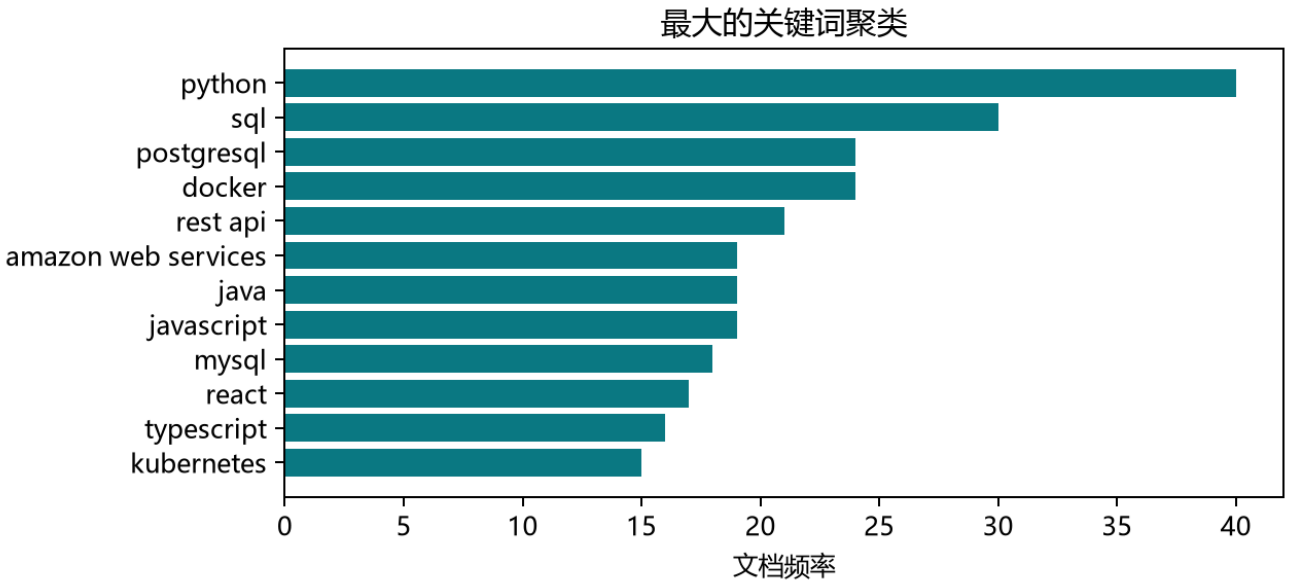


图 3. 最大的关键词聚类。

4.1 Bottleneck 消融

Bottleneck 维度	LOPO Recall@10	Recall@5	MRR@10	平均排名
16	0.200	0.200	0.100	17.9
32	0.800	0.400	0.320	9.3
64	0.600	0.300	0.266	19.3

16 维欠拟合，64 维在 10 组 GT 上过拟合；32 维的 LOPO Recall@10 最好。

4.2 主要观察

- **AE 与基线打平 Recall，但 MRR 更低**：LOPO Recall@10 = 0.80，与 TF-IDF / BM25 的 0.80 相同；但 AE 的 MRR@10 只有 0.32（TF-IDF 0.44），说明它能把正确 CV 找进 Top-10，却经常把相似的干扰 CV 排在更前面。
- **in-sample 严重乐观**：全部 10 组训练后同批评估为 1.00，而 LOPO 只有 0.80；10 组 GT 很容易被记住，报告必须以 LOPO 为准。
- **两个 miss**：P04（Data Engineer）排第 13（差一点），positive CV 缺少 Azure Synapse、PySpark 等 JD 关键词；P06（Deployment Strategist）排第 36，JD 是项目/客户/交付，hired CV 是 Data Science 背景，两边关键词几乎零重合，属于抽取/标签口径问题。

- **命中但排名靠后：**P02（Sales Manager in Indonesia）第 9、P07（Marketing Manager (HK & SG)）第 9、P09（Tech Lead）第 10；positive CV 与 JD 的显式关键词重合少，AE 主要靠隐向量把它们拉进 Top-10，但 top-1 常被领域不相关的 CV 占据（如 P08 的 top-1 是视频剪辑 CV）。
- **同义词仍是主要误差源：**flavour/flavor、key account management/client relationship management、B2B sales/international sales 等未完全合并，导致 P02/P07 的 positive 只共享 1 个 JD 关键词。

5. 改进方案

- **Must-have 加权：**把 JD 中 importance=3 的关键词单独作为门槛；缺少关键 must-have 的 CV 降权或直接过滤。
- **混合检索：**AE 向量 + BM25 / 关键词重叠的 hybrid score，兼顾语义与精确术语。
- **更好的关键词归一化：**扩展技能同义词表，区分 Java/JavaScript、SQL/MySQL、AWS/Azure/GCP 等易混词。
- **更多 GT：**10 组标签太少；建议人工补充 30–50 组 JD–CV 相关性判断，或做 pooled 人工评估。
- **类别感知编码：**按 skill/tool/domain 分块编码，避免通用职责词压过硬技能。

6. 局限

- 只有 10 组 GT，Recall 的统计置信区间较宽；10 个 query 的粒度是 0.1。
- Recall 只把“实际 hired CV”视为相关；其他潜在好 CV 未标注，因此指标偏保守。
- 候选池 110 份，规模较小；结论不应直接外推到大规模招聘。
- LLM 抽取存在类别漂移和漏抽；本报告未做大规模人工校对。

附录

A. LLM prompt（英文原文）

```
Extract 12-25 canonical keywords...
Return JSON: doc_id, doc_type, role_title, seniority,
years_experience, location, languages, keywords[{term, category, importance}].
"languages" must contain ONLY human spoken languages.
Programming languages use category "programming_language".
```

B. 复现

代码与中间结果位于 `HW4_6207/`；运行 `python src/train_eval.py --mode all` 可复现实验。随机种子固定为 42。

C. 每个 JD 的 Top-10 检索结果

下表是 LOPO 中每个 GT JD 实际返回的 10 份 CV（按相似度从高到低）。✓ 表示该 JD 的 hired CV；若 hired CV 不在表内，说明它的排名 > 10（P04 Data Engineer = 13，P06 Deployment Strategist = 36）。

JD / 职位	Hired CV 排名	Top-10 CV（1 → 10）
P01 Regional Finance Controller	2	1. CV-082 · **2. HIRED_P01** ✓ · 3. CV-044 · 4. CV-025 · 5. CV-050 · 6. CV-075 · 7. CV-046 · 8. CV-083 · 9. CV-028 · 10. CV-015
P02 Sales Manager in Indonesia	9	1. CV-062 · 2. CV-065 · 3. CV-022 · 4. CV-073 · 5. CV-049 · 6. CV-098 · 7. CV-099 · 8. CV-017 · **9. HIRED_P02** ✓ · 10. CV-083
P03 GTM Marketing Manager / Lead	1	**1. HIRED_P03** ✓ · 2. CV-023 · 3. CV-065 · 4. CV-066 · 5. CV-099 · 6. CV-069 · 7. CV-070 · 8. CV-073 · 9. CV-067 · 10. CV-049
P04 Data Engineer	13	1. CV-043 · 2. CV-031 · 3. CV-083 · 4. CV-022 · 5. CV-037 · 6. CV-041 · 7. CV-087 · 8. CV-040 · 9. CV-035 · 10. CV-061
P05 Product Manager — WMS & Warehouse Integrations	8	1. CV-065 · 2. CV-071 · 3. CV-100 · 4. CV-048 · 5. CV-097 · 6. CV-042 · 7. CV-023 · **8. HIRED_P05** ✓ · 9. CV-070 · 10. CV-022
P06 Deployment Strategist	36	1. CV-024 · 2. CV-016 · 3. CV-085 · 4. CV-010 · 5. CV-023 · 6. CV-066 · 7. CV-019 · 8. CV-009 · 9. CV-058 · 10. CV-018
P07 Marketing Manager (HK & SG)	9	1. CV-092 · 2. CV-099 · 3. CV-065 · 4. CV-023 · 5. CV-073 · 6. CV-022 · 7. CV-083 · 8. CV-035 · **9. HIRED_P07** ✓ · 10. CV-042
P08 Field Service Engineer (FSE)	4	1. CV-050 · 2. CV-063 · 3. CV-083 · **4. HIRED_P08** ✓ · 5. CV-067 · 6. CV-073 · 7. CV-082 · 8. CV-032 · 9. CV-031 · 10. CV-033
P09 Tech Lead	10	1. CV-010 · 2. CV-035 · 3. CV-037 · 4. CV-041 · 5. CV-083 · 6. CV-040 · 7. CV-092 · 8. CV-067 · 9. CV-042 · **10. HIRED_P09** ✓
P10 Regional Lead Designer UI/UX	1	**1. HIRED_P10** ✓ · 2. CV-037 · 3. CV-070 · 4. CV-042 · 5. CV-035 · 6. CV-041 · 7. CV-061 · 8. CV-040 · 9. CV-022 · 10. CV-074